離散期末報告

統資三甲 陳彥嘉 412421446

資料敘述與基本分析：

- **目標變數 (Label)**：`AQI.Category`，將空氣品質由好到壞分為 6 個等級（如 Good, Moderate 等）。
- **特徵變數 (Features)**：包含國家、城市、座標及各種空氣汙染物變數。

資料敘述與基本分析：

- **特徵變數 (Feature)**：
  - **污染物變數**：包括 PM2.5, Ozone (臭氧), CO (一氧化碳), NO2 等 AQI 數值。
  - **類別變數處理**：由於 `Country`（國家）與 `City`（城市）是文字，要將其轉化為 **Factor (因子)** 格式。
  - **避免報錯**：為了確保模型能正確預測 Test 資料，將 Test 集的類別 Level 強制與 Train 集同步，避免模型遇到「沒看過的城市」而報錯。(就是讓Test只能用Train用過的資料)

```r
# ================================
# 處理類別變數
# ================================
train$Country <- as.factor(train$Country)
train$City    <- as.factor(train$City)

test$Country <- factor(test$Country, levels = levels(train$Country))
test$City    <- factor(test$City, levels = levels(train$City))

train$AQI.Category <- as.factor(train$AQI.Category)
```

類別變數處理

一致性對齊

說明分析方法與建立統計模型：

- **演算法選擇：隨機森林 (Random Forest)**：
  - 我選用 R 的 **`ranger` 套件**，這是隨機森林的一種，適合處理大型資料集。
  - **模型邏輯**：透過集成 400 棵決策樹，能有效捕捉變數間的非線性關係。
- **參數配置**：
  - `num.trees = 400`：建立足夠數量的樹以確保預測結果穩定。
  - `mtry = 4`：隨機選取 4 個特徵進行分裂，增加模型的多樣性。
  - `importance = "impurity"`：設定計算「不純度重要性」，以便事後分析哪些污染物才是空氣污染的主因。(這個後面特徵重要性要用的)
- **驗證機制**：

  使用 **80/20 分割法**。先用 80% 的數據訓練模型，再用剩下的 20% 進行驗證，以計算模型在未知數據上的準確率。

```r
# ================================
# 訓練 / 驗證集切分
# ================================
set.seed(42)
train_idx <- sample(1:nrow(train), 0.8 * nrow(train))

train_data <- train[train_idx, ]
valid_data <- train[-train_idx, ]

# ================================
# 訓練 ranger 隨機森林
# ================================
model <- ranger(
  formula = AQI.Category ~ .,
  data = train_data,
  num.trees = 400,
  mtry = 4,
  importance = "impurity",
  probability = FALSE
)
```

資料敘述與基本分析：

- **特徵重要性 (Feature Importance)**：
  - 根據實驗結果圖表，PM2.5.AQI.Value 具有壓倒性的影響力。這說明 PM2.5 是判定 AQI 等級最重要的指標。
  - CO 與 Ozone 分列二、三名，顯示它們對等級的判定也有一定幫助。
  - 地理位置影響微弱，Country 與 City 的重要性排在末端，這證明空氣品質的好壞主要是由各種汙染物變數決定(尤其是PM2.5)，而非特定地點。
- **模型效能**：
  - **驗證準確率 (Validation Accuracy)**：0.996 。

```r
  importance = "impurity",
  probability = FALSE
)

library(ggplot2)
imp_data <- as.data.frame(importance(model))
colnames(imp_data) <- "Importance"
imp_data$Feature <- rownames(imp_data)

ggplot(imp_data, aes(x = reorder(Feature, Importance), y = Importance)) +
  geom_bar(stat = "identity", fill = "skyblue") +
  coord_flip() + # 轉為橫向
  labs(title = "Feature Importance (AQI Prediction)",
       x = "Features",
       y = "Importance (Node Impurity)") +
  theme_minimal()
```
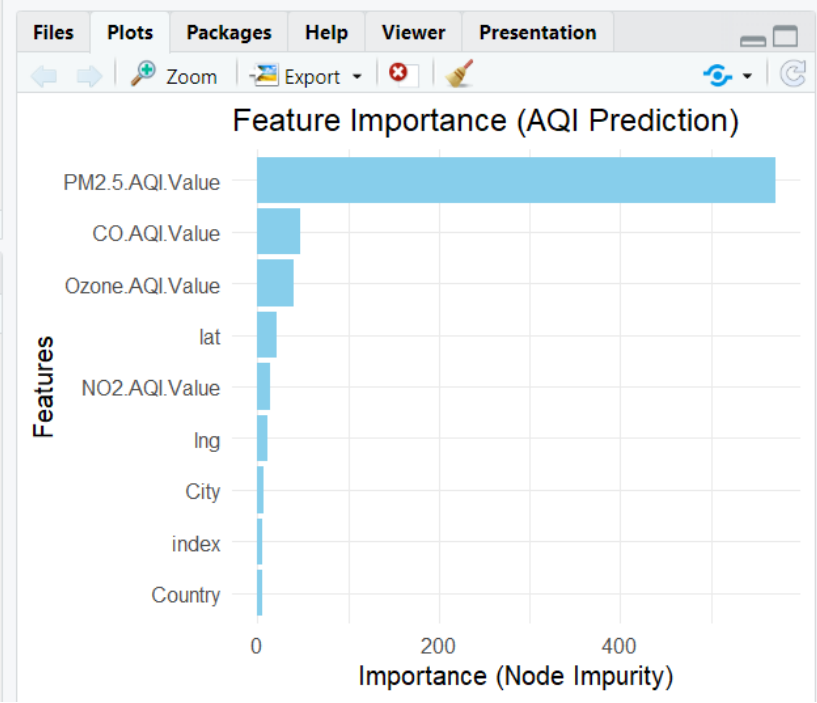
用ggplot畫出特徵重要性